# CD -Resumo Ch6-

# Considerações Iniciais

Este capitulo provem da ideia de que processos num ambiente distribuído necessitam de estarem sincronizados/coordenados para efetivamente trabalharem como suposto. São também abordados outros tipos de coordenação como Exclusao Mutua e algoritmos de Eleiçao.

#### Sincronização:

- **Process Synchronization:** Garantir que um processo espera por outro para completar a sua operação
- Data Synchronization: Garantir que 2 data sets são o mesmo (mais abordado no Ch7 – Replicação)

#### Coordenação:

- Gerir interações e dependências entre atividades num sistema distribuído
- Diz-se que "encapsula a sincronização"

## Clock Synchronization

#### -Considerações-

#### **Physical Clocks:**

- Os computadores tem um Timer
- O timer posusi um cristal de quartzo que oscila a uma frequência +- bem defenida quando sob tensão
- Associado ao cristal estão 2 registos 1 Counter que decrementa a cada oscilação; 1 Holding register que recarrega o counter quando este chega a 0
- Clock Tick: Quando o counter chega a 0 é gerado um interrupt
- Software Clock: A cada clock tick, e adicionado um ao valor de tempo guardado em memoria (aka atualizamos o software clock)
- É impossível garantir que cristais em varias maquinas oscilem à mesma frequência...so that's why we have problems
- Clock Skew: Diferença dos time values de diferentes timers

#### UTC - Universal Coordinated Time:

- Standard mundial
- Basis para menter tempo global
- Estações de radio e satélites oferecem este serviço
- Receivers recevem de vários satélites e ground time servers com uma accuracy de 50 nsec
- Relógio Atómico (Baseia-se na oscilação do átomo Celsiu-133)...so it's precise as heck

 Se um DS tiver um UTC Receiver algures, os outros componentes devem tentar sincronizar-se a este

#### Precision:

- Usado como "bound" da diferença de time values entre 2 timers
- Denota-se por Pi
- 2 relógios, p e q, são preciso se:
  - $\circ \qquad \forall t, \forall p, q: |Cp(t)-Cq(t)| \leq \pi$
  - Cx(t) -> Time value do relogio x no instante (UTC) t

#### Accuracy:

- Usado como "bound" da diferença de time values entre 1 timer e um UTC Receiver
- Denota-se por Alfa
- 1 relógios, p, é exato se:
  - $\circ \qquad \forall t, \forall p: |\mathit{Cp}(t) t| \leq \alpha$
  - o Cx(t) -> Time value do relogio x no instante (UTC) t

#### Nota: Usamos:

-Precision para manter INTERNAL SYNCHRONIZATION

-Accuracy para manter EXTERNAL SYNCHRONIZATION

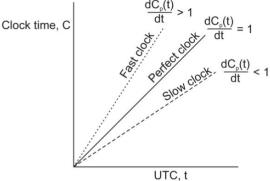
Nota: Um set de relógios accurate em alfa também será precise em pi=2\*alfa

Nota: Caso ideal seria termos Precision = Accuracy = 0, e Cp(t) = t, sempre...but life ain't that good :(

#### Clock Drift:

- A frequência dos relógios não e perfeita e e afetada por fatores externos, portanto clocks em diferentes maquinas vao gradualmente começar a mostrar diferentes valores de tempo – Clock Drift Rate
- Existe um **Maximum clock drift rate Ró** dependente do hardware clock
- Devemos procurar manter o Software clock drift rate bounded a Ró

1-Ro <= dCp(t)/dt <=</li>1+Ro



Nota++: Para assegurarmos que clocks são Precisos para pi (não diferem os seus time values mais de pi), temos que RESINCRONIZAR (em software) os relógios a cada Pi/2(Ro) segundos!

# Clock Synchronization

#### -Algoritmos-

#### **Network Time Protocol:**

- É simétrico (i.e 2 servidores A e B, A pode procurar ajustar o seu time segundo B, ou B segundo A)
- Ideia: Procurar sincronizar o tempo segundo um outro servidor (preferencialmente um com UTC receiver), mas tendo em conta os delays que acompanham a troca de mensagens de sincronização.
- Algoritmo: Procuramos encontrar uma boa estimação do time delay e obter o offset de tempo entre 2 servers da seguinte forma:
  - 1) A manda um request a B, timestamped com o valor TI.
- B  $T_{1}$   $\delta T_{req}$   $\delta T_{res}$
- 2)B aponta ο Α δΤ<sub>ες</sub> δΤ<sub>ες</sub>
   tempo que que recebeu o pedido, T2, e manda uma resposta a A timestamped com o tempo em que a envia, T3, e com o tempo de receção T2 em piggyback
- 3)A aponta o tempo em que recebeu a resposta de B, T4, e com a informação colecionada ate agora consegue calcular o offset:
  - Offset = ((T2-T1) + (T3-T4))/2
- 4)A vai ajustar o seu internal clock acelerando (caso esteja atras) ou desacelerando (case esteja a frente) a rotina de interrupts ate acertar o tempo (e.g, se antigamente 100 interrupts eram gerados por segundo, e adicionavam 10msec ao tempo, para

desacelerar fazemos com que 100 interrupts/segundo gerem adicionem apenas 9msec)

• Nota: B também vai calcular o offset a A com a mesma formula, e vai também calcular um delay com a formula delta = ((T4-T1)-(T3-T2))/2. Normalmente são guardaos 8 pares (Offset,Delay) e depois escolhe-se o que tiver o valor mínimo do delay como melhor estimação do delay entre 2 servers (e o offset associado como a mais reliable estimation)

#### Nota++:

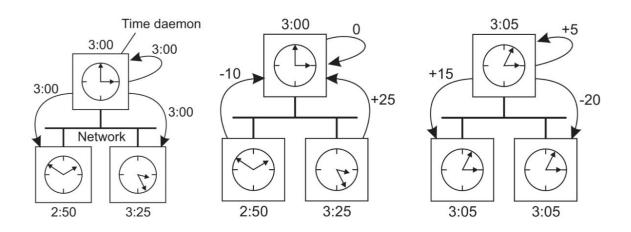
- Não faria sentido B sincronizar-se com A caso B fosse mais accurate (p.ex se tivesse um UTC Receiver).
- Para evitar situações estupidas, os relógios estão classificados em Strata.
- o UTC Receiver clocks são considerados em Stratum-1.
- Um relógio so se sincroniza por outro, caso esteja num Strata superior (p.ex A so se sincroniza com B se Strata A > Strata B).
- No caso de A se sincronizar com B, A sobe para (Strata B – 1)

#### Algoritmo de Berkley:

- É simétrico (i.e 2 servidores A e B, A pode procurar ajustar o seu time segundo B, ou B segundo A)
- Ideia: Ao contrario do NTC, assume-se que não temos nenhum relogio particularmente Accurate, e queremos so manter Internal Synchronization. Para tal um time server, que ao contrario do NTC, é ATIVO, vai pedir o

tempo a todas as maquinas e computar uma average. Depois diz a todas as maquinas se devem atrasar ou acelerar para ficarem sincronas

- Algoritmo: Os pedidos são tratados por time daemons e vao realizar as seguintes operacoes:
  - 1) A pede a todos os outros clocks os seus tempos (incluindo a si próprio)
  - o 2)A calcula os time offsets utilizando uma average
  - 3)A avisa todos os outros clocks se devem, e por quanto, se atrasar/adiantar (incluindo a si mesmo)
  - 4) Relógios acertam-se e ficam portanto sincronizados entre eles

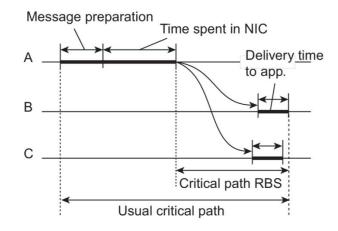


#### Reference Broadcast Synchronization (RBS):

- Não é simétrico!
- Usado em wireless networks onde assumçoes como reliable communication entre machines e disseminação de informação simples não existe e onde conservação de energia e multihop routing caro são fatores a considerar

#### Ideia:

- Tal como no Berkley's n\u00e3o se assume que temos um clock particularmente Accurate, procurando portanto sincroniza\u00e7\u00e3o interna.
- Não é síncrono pois permite que os receivers se sincronizem mantendo o sender out of the loop.
- Um sender basicamente envia em broadcast uma mensagem de referencia que permitirá aos receivers ajustar os seus relógios.
- O tempo de propagação a considerar aqui e medido a partir do momento em que a mensagem sai da network interface do sender!
- Quando um node broadcast uma reference message m, cada no p guarda o tempo Tp,m em que recebeu m (este tempo é lido do local clock do p).
- 2 Nodes p e q conseguem trocar os seus delivery times para estimar o seu mutual relative offset, desta forma p saberá o valor do relogio de q relativo ao seu próprio
- Devido ao drift porém, uma simples troca de medias não e a melhor forma de calcular o offset, devemos portanto usar uma regressão linear



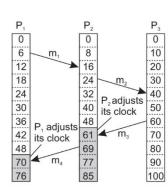
p

# Logical Clocks

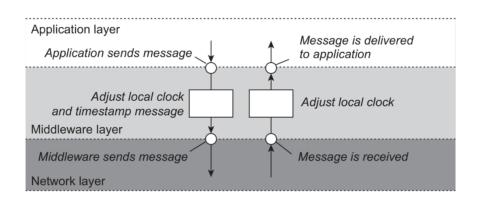
"Por vezes, não nos interessa que os clocks em si estejam sincronizados, queremos apenas que as operações sejam executadas ordenadamente"

#### Lamport's Logical Clocks:

- Baseia-se na ideia da relação happens before:
  - o A->B
  - o Lê-se: "A acontece antes de B"
  - Significa que TODOS OS PROCESSOS concordam que o evento A acontece antes do evento B
  - o Observa-se diretamente em 2 situações:
    - Se a e b são 2 eventos no mesmo processo, e a acontece antes de b, então a->b==True
    - Se a é o evento correspondente ao envio de uma mensagem num processo, e b o evento correspondente a receção dessa mensagem noutro processo, então a->b==True
  - Eventos em que a->b == False e b->a == False dizemse Concorrentes
- Queremos garantir que, se a->b então C(a) < C(b) Onde C(x) corresponde ao time value em que ocorre x –
   Independentemente do processo em que a e b ocorrem
- Algoritmo:
  - 1)Antes de executar um evento(i.e mandar uma mensagem), processo Pi incrementa Ci++
  - 2)Quando processo Pi manda a mensagem,m,
     inclui nela o timestamp, ts(m), com o seu Ci atual
  - 3)Quando um processo Pj recebe a mensagem,
     ajusta o seu Cj = max{Cj, ts(m)}
  - o 4)Pj incrementa Cj++
  - o 5)Pj entrega a mensagem a sua aplicação.



- Nota++: Temos 3 camadas: Application, Middleware e Network: A camade de middleware é a que executa o algoritmo de lamport, e depois entrega a mensagem a application para fazer o que quiser com ela. A network layer e responsável pelo envio e receção das mensagens
- Nota: Cada processo, Pi, mantem local counter, Ci



#### **Vector Clocks:**

- Relógios de Lamport can't actually capture, se, caso C(a) <</li>
   C(b), a tenha efetivamente acontecido antes de b
  - o Lamport's Clocks: C(a)<C(b) não implica a->b
- Não é capturada CAUSALIDADE
- Podemos facilmente capturar causalidade ao associa a cada evento um nome único e usando um contador local em que pk e o kth event que aconteceu no processo P.
- O problema ai é keeping track das Causal Histories (e.g se pl e p2 são 2 eventos que aconteceram sucessivamente no processo P, então o causal history de p2 H(p2) = {p1,p2})
- Ao enviarmos uma mensagem (i.e evento p3 envio de mensagem) de P ate Q, vamos ter a causal history de q1 – evento de receção da mensagem em Q – H(q1) = {p1,p2,p3,q1}
- Para verificarmos se um evento p causalmente precede um evento q precisamos apenas de verificar se H(p) está

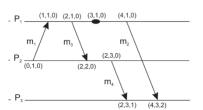
- contido em H(q) Neste exemplo, p2 causalmente precede q1, p.ex
- O problema com esta tática e que causal histories são merdosas em termos de representação eficiente. So fuck that we're gonna use Vector clocks baby

#### • Algoritmo:

- o 1) Antes de executar um evento (i.e mandar uma mensagem para outro processo ou entregar uma mensagem à application layer ou outro qualquer evento interno), Pi incrementa VCi[i]++ (equivale a dizer que aconteceu um novo evento em Pi)
- 2)Quando Pi envia uma mensagem m a Pj, inclui o seu VCi como timestamp na mensagem, ts(m) (apos ter claro incrementado VCi[i]++ visto ir realizar um evento de envio)
- 3)Quando Pj recebe uma mensagem, para todo o k,
   vai fazer VCj[k] = max{VCj[k], ts(m)[k]}
- o 4) Pj incrementa VCj[j]++
- o 5) And we go back to step 1
- Nota++: Para verificar se um evento causalmente precede outro temos apenas que comparar o ts(m1)

Situação	ts(m2)	ts(m4)	ts(m2) < ts(m4)	ts(m2) > ts(m4)	Conclusão
а	(2,1,0)	(4,3,0)	Sim	Não	m2 aconteceu antes de m4
b	(4,1,0)	(2,3,0)	Não	Não	m2 e m4 podem estar em conflito

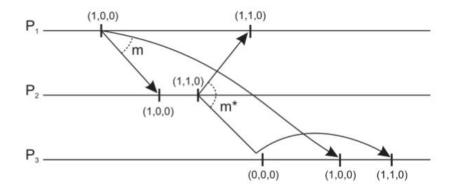
 Nota: Cada processo, Pi, tem um vector clock VCi com um length = numero de processos e cujo valor de VCi[i] corresponde ao numero de eventos que aconteceram em i a cada momento.



- Nota++: também que o incremento é feito, não quando se recebe a mensagem per se, mas quando ela é entregue à application layer
- Nota++: Se um evento tem um timestamp ts(a), então ts(a)[i]-1 == Numero de eventos processados em Pi que causalmente precedem a

#### Enforcing Causal Communication

- Podemos, usando vector clocks, garantir que uma mensagem so é entregue se a que a mensagem que lhe causalmente precede também tiver sido recebida
- o Causal Ordered Multicasting (kind of)
- Assumindo que os clocks são ajustados apenas ao enviar e receber mensagens, então, quando Pj recebe uma mensagem, a entrega desta à application layer sera delayed ate que:
  - 1) ts(m)[i] = VCj[i] + 1
  - 2) ts(m)[k] <= VCj[k] para todo k!=i
- A primeira condição diz que m tem de ser a próxima mensagem que Pj estava a espera de receber de Pi
- A segunda condição garante que Pj entregou todas as mensagens anterio res que foram entregues por Pi quando mandou a mensagem m



### Mutual Exclusion

#### -Considerações-

Por vezes, para garantir que acessos concorrentes por vários processos ao mesmo recurso não o corrompam, temos que garantir que o acesso é feito por exclusão mutua (i.e apenas um de cada vez)

Temos 2 tipos de algoritmos para o fazer:

#### Token Based Solutions

- Existe um token que é passado pelos processos.
- Apenas o processo que tem o token tem acesso ao recurso partilhado
- Quando o acesso e terminado, o token e passado ao próximo processo
- Caso o processo não queira acesso, passa simplesmente o token
- Previnem Starvation e Deadlocks!
- Mas...Se o token se perder temos problemas porque precisamos de gerar um novo and thats big oof

#### Permission Based Approach

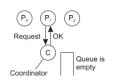
 Procesos que quer aceder a um recurso pede permissão aos outros recursos primeiro

## Mutual Exclusion

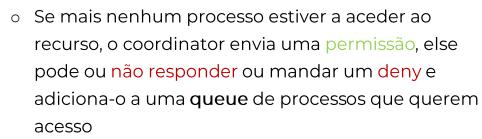
-Permission Based Algorithms-

#### Centralized Algorithm:

#### Algoritmo:



- Basicamente, temos um processo que é elegido como Coordinator
- Quando um processo quer aceder a um recurso partilhado, pede permissão ao coordinator





- Quando um processo que esteja a usar o recurso tiver terminado, avisa o coordinator para que este possa dar permissão a outro processo que tenha na queue de requests
- +Evitamos Starvation (visto que o algoritmo é justo) e
   Deadlocks
- +Facil de Implementar
- -Coordinator e um single point of failure
- -Dificil distinguir coordinator morto de um deny (o que pode levar a bloqueios de processos)
- -Coordinator pode tornar-se num bottleneck
- Still..solucoes distribuídas não são necessariamente melhores... sad

#### Decentralized Algorithm:

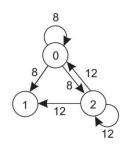
- Assume-se que cada resource está replicado N vezes e que cada replica tem um coordenador que controlo o acesso concorrente por processos!
- Quando um processo quer aceder a um recurso, pede aos coordenadores, e tem de receber uma maioria de votos de aceitação m>N/2 (i.e pelo menos metade dos coordenadores deixam que ele aceda)
- Quando um coordenador não der permissão de acesso ao recurso (i.e já deu a um outro) vai dizer ao requester
- Assume-se que quando um coordenador crasha recupera rapidamente mas vai se ter esquecido do voto dado antes de crashar
- Corremos o risco de um coordenador dar incorretamente permissão de acesso a vários processos (apos ter recuperado) mas...
- Em geral a probabilidade de acontecer merda mesmo apos o coordenador crashar, é tao pequena que podemos ignora-la
- Um processo que seja denied assume que passado algum tempo poderá ter acesso, logo voltara a pedir mais tarde
- -Se muitos nodes tentarem aceder ao mesmo recurso a utilização baixa rapidamente pois existem tantos recursos a competir peloa cesso que eventualmente, nenhum sera dado permissão pela maioria dos coordinators:(

#### Decentralized Algorithm:

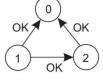
 Baseado no total ordering of all events in the system (i.e, para todos os pares de eventos, nao Podemos ter duvidas sobre qual aconteceu primeiro)

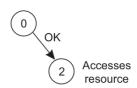
#### • Algoritmo:

- 1) Processo que quer aceder ao recurso constrói uma mensagem (que contem o nome do recurso), o seu process number/name e o seu current logical time
- 2) Essa mensagem é enviada a todos os outros processos que também acedem ao recurso, e assume-se que o envio da mensagem é reliable
- 3) Quando um processo recebe um pedido de acesso ele tem 3 opcoes:
  - Não está a aceder ao recurso, nem quer acesso – Envia uma resposta de OK
  - Já esta a aceder ao recurso Não responde mas regista numa queue o processo que mandou a mensagem
  - Não está a aceder ao recurso MAS quer acesso – Compara o timestamp da incoming message com o contido na mensagem que enviou a todos os outros. Se a mensagem que recebeu tiver um timestamp menor, o receiver manda um Ok; Else, o receiver guarda numa queue o pedido e não manda nada
- 4)Depois de enviar os pedidos, um processo espera ate receber um Ok de todos os outros
- 5) Quando um processo termina o acesso ao recurso, envia um Ok a todos os processos que tenha na queue









- -N points of failure (precisamos de um Ok de todos os processos...)
- -Temos de usar multicast communcation ou cada processo tem de manter uma group membership list
- -Todos os processos estão envolvidos em Todas as decisões de acesso...xtra burdon :(
- Podemos modificar o algoritmo para o tornar melhor,
   p.ex fazer com que o acesso seja permitido apos se ter
   recebido um Ok da maioria dos processos

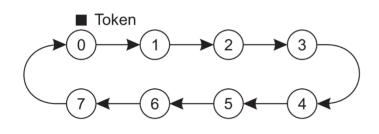
## Mutual Exclusion

#### -Token Based Algorithms-

#### Token-Ring:

• Os processos estão organizados numa overlay network

com a forma de um logical ring, na qual cada processo é dado uma posição no ring!



- Cada processo conheço qual o processo que lhe sucede no ring
- Quando o ring é iniciado, é dado um Token a um processo arbitrário (p.ex PO)
- O token circula pelo ring sendo passado de node em node
- Quando um processo recebe o token, verifica se quer aceder ao shared resource.
  - Se sim: Acede ao recurso e depois liberta o token, passando-o ao seu sucessor
  - o Se não: Passa o token para o seu sucessor
- +Evitamos Starvation (visto que o algoritmo é justo) e
   Deadlocks
- +Pior dos casos, um processo tem de esperar que o token passe por todos os outros processos antes de poder aceder ao recurso
- -Se perdermos o token temos que criar um novo (pode acontecer caso um processo com o token crashe)

- Detetar a perda do token não é fácil pois nunca temos certeza se o token se perdeu ou se um processo esta a demorar muito tempo a usa-lo
- Garantir que um processo recebeu um token implica que este envie uma mensagem de receive. Caso seja detetado que o processo morre, para reconstruir o rign e preciso que todos os processos mantenham a configuração atual do ring guardada...
- Nota: Cada processo, ao adquirir o token, pode aceder ao recurso partilhado apenas uma vez (não pode entrar, sair e voltar a entrar logo, pois tem que passar o token para a frente)

## Mutual Exclusion

-Comparação de algoritmos-

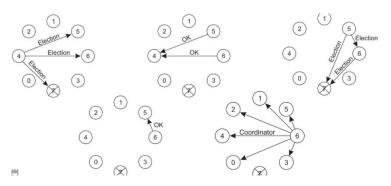
Algoritmo	Mensagens por entrada/saída	Atraso antes da entrada (em tempos de mensagem)	Problemas
Centralizado	3	2	Coordenador crasha
Descentralizado	2 m k + m, k = 1,2,	2 m k	Fome, baixa eficiência
Distribuido	2 (n-1)	2 (n-1)	Crash de um qq processo
Token Ring	1 a inf	0 a n - 1	Perda token

# **Election Algorithms**

#### -Algorithms-

#### **Bully Algorithm:**

Consideram-se N
 processos, P0 ate Pn 1, cada processo com
 um id(Pi) = i. (onde i é
 um numero)

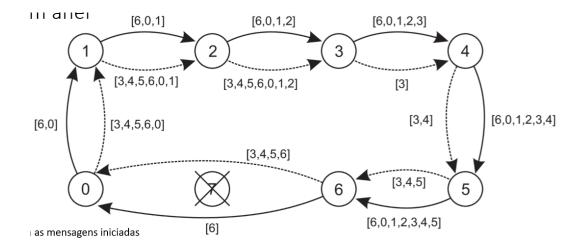


#### • Algoritmo:

- 1) Processo Pi repara que o coordinator/leader não está a responder a pedidos, logo vai iniciar a eleição
- 2) Pi vai enviar uma ELECTION message a todos os processos cujos identifiers sejam maiores do que o seu (Nota: também poderia mandar aos que fossem menores)
- 4) Se ninguém responder, Pi ganha e torna-se o coordinator enviando uma mensagem a avisar todos os outros
- 5) Se alguém responder, repete o algoritmo começando no passo 1)
- A qualquer momento, um processo tem de estar pronto para receber uma ELECTION message e responder com um Ok (caso tenham um id maior do que o sender), passando assim a realizar uma eleição (CASO AINDA NÃO ESTEJA A FAZER UMA)
- Eventualmente todos os processos desistem exceto um
- Se o coordenador que morreu recomeçar, avisa todos os outros que se tornara de novo o coordenador

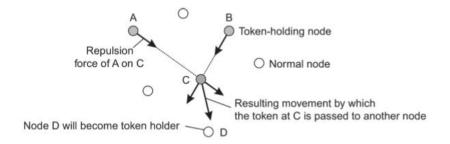
#### Ring Algorithm:

- Baseado no uso de um ring logico mas sem uso de token.
- Assume-se que cada processo conhece o seu sucessor
- Algoritmo:
  - 1) Processo Pi repara que o coordinator/leader não está a responder a pedidos, logo vai iniciar a eleicao
  - 2) Pi vai enviar uma ELECTION message ao seu sucessor contendo o seu próprio id (caso o sucessor esteja morto, o sender salta esse manda para o próximo)
  - 4) Processo Pj recebe a mensagem, da append do seu próprio id à lista contida na mensagem e repete o paço 2)
  - 5) Quando a mensagem voltar ao no que a iniciou (i.e quando um no reparar que o seu id já esta na lista), este ve qual e o maior id na lista, e escolhe esse como coordinator
  - 6) Manda mensagem COORDINATOR a circular pelo no, para que todos registem quem e o novo coordinator



#### Election in large-scale systems:

- Temos situações em que VARIOS nodes devem ser selecionados como especiais (p.ex no caso dos Super Peers em P2P Networks)
- Requirements para seleção de super peer:
  - Normal nodes devem ter pouca latência de acesso aos super peers
  - Super peers devem estar distribuídos uniformemente
  - Deve haver uma porcao predefenida de super peers relativa ao total numero de nodes na overlay network
  - Cada super peer n\u00e3o deve servir mais do que um fixo numero de nodes
- Algoritmo (baseado no positioning de nodes em mdimensional geometric spaces – Queremos colocar N super peers evenly pela overlay):
  - 1) São espalhados N tokens por N randomly chosen nodes na overlay network (um node pode ter no máximo 1 token)
  - 2) Cada token representa uma repelling force que inclina outros tokens a se afastarem (requer que nodes que tenham tokens saibam que outros nos também tem tokens)
  - 4) Quando um node tiver um token durante x tempo, promove-se a super peer



# **Location Systems**

#### -Actual Positioning-

Num sistema distribuído de larga escala, em que os nós se encontram dispersos numa WAN é comum o sistema ter em atenção a noção de proximidade e/ou distância

Para tal é necessário determinar a localização do nó.

#### Global Positioning System - GPS:

- Usa vários satélites que circulame em orbita
- Cada satélite tem 4 clocks atómicos regularmente calibrados
- Cada satélite continuamente faz broadcast da sua posição e time stamps cada mensagem com o seu local time
- Com isto qualquer receiver na terra consegue facilmente computar a sua posição usando, em principio, apenas 4 satelites
- Um nó precisa de d+1 marcos de referencia (satélites)
   para calcular a sua posição num espaço d-dimensional

#### WiFi Access Points:

- Usa-se quando n\u00e3o podemos usar o GPS (p.ex em ambientes fechados)
- Se tivermos acesso a uma base de dados de conhecidos pontos de acesso (e as suas coordenadas), podemos estimar a nossa distancia a um ponto de acesso e,

- fazendo isto com apenas 3 pontos, conseguimos computar a nossa posição
- Problemas ocorrem em determinar as coordenadas de um ponto de acesso (para isso usa-se War Driving)
- Memso assim so conseguimos estimações das coordenadas, portanto a accuracy vai sofrer

# **Location Systems**

#### -Logical Positioning-

Podemos, em vez de encontrar uma localização absoluta de um node, tentar capturar apenas uma logical, prxoimity based location.

Distancia, nestes casos, pode p.ex corresponder a latência entre 2 nodes

Alguns usos uteis incluem encontrar optimal replica placement

#### **Centralized Positioning:**

- Como já vimos, para posicionar um node num mdimensional geometric space precisamos de m+1 marcos de distancia a nodes com posições já conhecidas
- Com apenas 1 teriamos um circulo no qual o nosso node se encontra, com 2 teriamos a interseção de 2 circulos que nos daria 2 pontos possíveis, e com 3 temos então um único ponto correspondente a localização atual
- O problema com usar latência como distancia é que não tende a ser estável, o que leva a diferentes posicionamentos de P sempre que se calcula a sua posição.
- Por outro lado, nodes que usem P como marco vao ter um erro ainda maior caso este contenha erros
- Measured distances between a set of nodes will generally not be consistent